

Detección de patrones de apnea del sueño mediante análisis de señales fisiológicas

Nataly Rodriguez Atehortua^{1*}

¹ Maestría en ingeniería, Universidad de Antioquia

Resumen

La apnea obstructiva del sueño (AOS) es un trastorno respiratorio caracterizado por episodios recurrentes de obstrucción de las vías aéreas, asociados a desaturaciones de oxígeno y alteraciones en la variabilidad cardíaca. Este estudio analiza señales fisiológicas no invasivas —ECG, saturación de oxígeno y flujo respiratorio— para identificar patrones relacionados con eventos de apnea. Se trabajó con registros de la base Apnea-ECG, segmentados en épocas de un minuto etiquetadas como normales o con apnea, de las cuales se extrajeron características temporales y frecuenciales. Se identificaron outliers mediante IQR, Z-score y DBSCAN, considerando como no plausibles los valores fuera de rangos fisiológicos, y se imputaron mediante mediana o aleatoria por clase, siendo esta última la más efectiva. A continuación, se aplicaron transformaciones logarítmica y Yeo-Johnson para corregir sesgos y estabilizar la varianza, y se implementaron técnicas de balanceo de clases para optimizar la formación de clústeres mediante K-Means. Los resultados mostraron diferencias consistentes entre épocas con y sin apnea, especialmente en desaturaciones de oxígeno y variabilidad cardíaca y respiratoria. El análisis de clúster complementado con SMOTE presentó una clasificación coherente con las etiquetas reales, con precisión y F1-score superiores al 90 %, estableciendo una base metodológica sólida para el desarrollo de sistemas de detección y predicción de eventos respiratorios asociados a AOS.

Palabras clave: Apnea-ECG, apnea del sueño, ECG, SpO₂, flujo respiratorio, HRV, outliers, imputación, K-Means

I. Introducción

La apnea obstructiva del sueño (AOS) es un trastorno respiratorio de alta prevalencia, caracterizado por episodios recurrentes de obstrucción parcial (hipopnea) o total (apnea) de las vías aéreas superiores durante el sueño, que generan una interrupción del flujo de aire hacia los pulmones por un periodo mínimo de 10 segundos [1]. De acuerdo con los criterios diagnósticos de la American Academy of Sleep Medicine (AASM), una apnea se define como una reducción $\geq 90\%$ del flujo aéreo con respecto al valor basal, mientras que una hipopnea corresponde a una disminución $\geq 30\%$ de la señal de presión nasal, acompañada de una desaturación arterial de oxígeno $\geq 4\%$ [2].

En Colombia, entre 2017 y 2021, se registraron 363 204 casos de apnea del sueño, lo que equivale a una prevalencia de 21,67 casos por cada mil habitantes mayores de 50 años. La mayor proporción de diagnósticos se concentra en Bogotá, Cundinamarca, Antioquia y Valle del Cauca, regiones que en conjunto representan el 83,1 % de los casos reportados en el país [3]. A nivel global, se estima que este trastorno afecta aproximadamente a 936 millones de adultos entre los 30 y 69 años [4].

En los pacientes con apnea obstructiva del sueño (AOS), la calidad del sueño se ve profundamente comprometida, con un impacto particularmente mar-

cado durante la fase de sueño REM (Rapid Eye Movement), periodo en el que el tono muscular disminuye de forma significativa y aumenta la susceptibilidad al colapso de las vías respiratorias superiores [5]. La obstrucción repetitiva del flujo aéreo fragmenta la continuidad del sueño, altera la arquitectura normal de las etapas y reduce la oxigenación adecuada a lo largo de la noche. Cuando no se trata, la AOS puede derivar en consecuencias sistémicas relevantes, como alteraciones en el metabolismo de la glucosa, diabetes mellitus, síndrome metabólico, enfermedades cardiovasculares y deterioro neurocognitivo [6].

La presión positiva continua en la vía aérea (CPAP) constituye el tratamiento de referencia para la apnea obstructiva del sueño (AOS) [7]. No obstante, su adherencia clínica sigue siendo limitada, con reportes que indican tasas de uso a largo plazo de hasta apenas el 30 % [8]. Una de las razones subyacentes es el empleo de algoritmos propietarios de ajuste de presión, los cuales pueden clasificar erróneamente los eventos respiratorios o confundirlos con artefactos de señal [9].

Los sistemas de presión positiva automática (APAP) detectan eventos respiratorios principalmente mediante la monitorización de disminuciones en la amplitud del flujo. Para ello, los algoritmos comparan ventanas de análisis de corto plazo —como un solo ciclo respiratorio o periodos de aproximadamente 2 segundos— con ventanas de referencia más largas. Se identifica un episodio de apnea o hipopnea cuando la amplitud del flujo desciende por

*Correspondiente autor: nataly.rodriguez1@udea.edu.co

debajo de un umbral predefinido durante al menos 10 segundos [10].

Los fabricantes difieren en sus metodologías de procesamiento de señal. Por ejemplo, ResMed™ emplea señales de flujo filtradas y escaladas, integradas mediante un cálculo del valor cuadrático medio (RMS) para estimar variaciones respiratorias [10]. Aunque estos algoritmos basados en umbrales siguen siendo fundamentales en los dispositivos APAP, investigaciones recientes han incorporado modelos de aprendizaje automático y profundo para mejorar la detección de eventos. Estas estrategias combinan señales como el flujo respiratorio, el ECG y la SpO_2 con el fin de capturar patrones no lineales y dinámicas temporales características de la fisiopatología de la AOS [11, 12].

Este trabajo propone la identificación de patrones asociados a la apnea obstructiva del sueño a partir de señales fisiológicas no invasivas. Para ello, se analizan características extraídas de registros de flujo respiratorio, saturación de oxígeno (SpO_2), intervalos RR y medidas de variabilidad de la frecuencia cardíaca (HRV). Esta fase inicial del estudio incluye un análisis exploratorio de los datos, la identificación y el tratamiento de valores atípicos, así como la aplicación de técnicas de agrupamiento con el fin de reconocer características relevantes que puedan emplearse posteriormente en sistemas de detección o predicción de eventos respiratorios.

II. Metodología

El flujo de trabajo metodológico se estructuró en cinco etapas consecutivas. En primer lugar, se llevó a cabo la recopilación y descripción de las variables derivadas de las señales fisiológicas empleadas en el estudio. A continuación, se realizó un análisis exploratorio, orientado a examinar la distribución de los datos y las relaciones preliminares entre las variables.

La segunda etapa consistió en la detección y análisis de valores atípicos, seguida de su tratamiento mediante técnicas de imputación, con el objetivo de garantizar la calidad y consistencia del conjunto de datos. Posteriormente, se aplicaron transformaciones estadísticas destinadas a mejorar el comportamiento y la estabilidad de las variables.

Finalmente, se efectuó un balanceo de clases y un análisis de clúster, con el fin de identificar patrones relevantes y evaluar la capacidad de las variables para discriminar entre diferentes condiciones respiratorias.

A. Descripción del conjunto de datos y análisis exploratorio

Características de los datos a utilizar

Este trabajo utilizó la base de datos Apnea-ECG, disponible de forma gratuita en el repositorio PhysioNet [13]. Esta colección de registros fue proporcionada por el Prof. Dr. Thomas Penzel en el marco del Computers in Cardiology Challenge 2000 y ha sido ampliamente utilizada en investigaciones sobre apnea del sueño [14]. Los registros corresponden a siete sujetos masculinos y una femenina, con edades comprendidas entre 31 y 64 años (media \pm desviación estándar (std): 43 ± 8 años). Las estaturas oscilan entre 168 y 184 cm (media \pm std: 177 ± 6 cm), y los pesos entre 63 y 121 kg (media \pm std: 88.5 ± 22 kg) [15]. Cada registro incluye un electrocardiograma de una sola derivación (ECG), la saturación de oxígeno (SpO_2) y el flujo oro-nasal medido mediante termistores. Todas las señales fueron muestreadas a una frecuencia de 100 Hz y ya se encontraban preprocesadas, por lo que no fue necesario aplicar filtros adicionales en esta etapa del análisis.

Las anotaciones en la base de datos se proporcionaron en segmentos de un minuto. Cada época de 60 segundos fue etiquetada manualmente por un experto, donde la etiqueta "A" indicó la presencia de un evento de apnea al inicio del minuto y la etiqueta "N" señaló su ausencia [13]. Para garantizar la calidad de los datos, se excluyeron las épocas que presentaban valores de saturación de oxígeno igual a cero, ya que se consideraron no fisiológicas o producto de artefactos. El conjunto final de datos estuvo compuesto por 1506 épocas con eventos de apnea y 2286 sin eventos, las cuales constituyeron la base sobre la que se llevaron a cabo los procesos.

Extracción de características

A partir de cada época de 60 segundos, se realizó la extracción de características en los dominios temporal y frecuencial, diferenciando según el tipo de señal fisiológica analizada.

Para la señal de ECG, se analizaron los intervalos RR, los cuales se obtuvieron tras la detección de los picos R mediante un algoritmo basado en la función `find_peaks`. Para ello, se empleó un umbral adaptativo equivalente al 50 % de la amplitud máxima del segmento y una distancia mínima entre picos de 0.5 segundos. Este procedimiento permitió identificar los latidos cardíacos y, con ello, calcular los intervalos RR. A partir de dichos intervalos, se extrajeron seis características en el dominio temporal: promedio (*mean_rr*), mediana (*median_rr*), varianza (*var_rr*), desviación estándar (*std_rr*), la raíz cuadrada de la media de las diferencias cuadráticas sucesivas (*rmssd*) y la

varianza del cociente entre intervalos consecutivos (*var_rr_ratio*) [16, 17].

En el dominio frecuencial, se consideraron las bandas de baja frecuencia (LF: 0.04–0.15 Hz) y alta frecuencia (HF: 0.15–0.40 Hz). El espectro se estimó mediante el método de Welch con ventana de Hanning, a partir del cual se calculó la razón LF/HF (*hrv_lf_hf_ratio*) [16].

Para la señal de oximetría (SpO₂), se extrajeron cinco características en el dominio temporal: promedio (*spo2_mean*), desviación estándar (*spo2_std*), varianza (*spo2_var*), valor mínimo (*spo2_min*) y valor máximo (*spo2_max*) por época [17, 18]. En el caso de la señal de flujo respiratorio, se calcularon tres características temporales: promedio (*airflow_mean*), mediana (*airflow_median*) y desviación estándar (*airflow_std*). Adicionalmente, se extrajeron dos características en el dominio frecuencial utilizando el método de Welch con ventana de Hanning y un solapamiento del 50 %. A partir del espectro estimado, se obtuvo la media espectral en los rangos de 0–0.1 Hz (*airflow_mean_PSD_0_0.1*) y 0.4–0.5 Hz (*airflow_mean_PSD_0.4_0.5*) [18].

Análisis exploratorio

Se realizó un análisis exploratorio de las características extraídas considerando la presencia ('A') o ausencia ('N') de eventos de apnea. Inicialmente, se emplearon diagramas de caja (boxplots) normalizados para comparar de manera uniforme las distribuciones de las distintas señales fisiológicas según su etiqueta. Asimismo, se analizaron las relaciones entre las variables mediante correlación de Spearman, con el objetivo de identificar dependencias no lineales entre los atributos.

B. Detección y análisis de valores atípicos

La detección de valores atípicos se realizó utilizando tres metodologías complementarias: el rango intercuartílico (IQR), el Z-score y el algoritmo de agrupamiento DBSCAN.

- **Rango intercuartílico (IQR):** Esta técnica mide la variabilidad de los datos dividiendo el conjunto en cuartiles. Se consideraron como valores atípicos aquellos puntos que se encuentran por debajo de $Q_1 - 1,5 \times IQR$ o por encima de $Q_3 + 1,5 \times IQR$ [19].
- **Z-score:** El Z-score describe qué tan alejado se encuentra un punto de la media, expresado en desviaciones estándar. Se consideraron valores atípicos aquellos con Z-score mayor a 3 o menor a -3, es decir, a más de tres desviaciones estándar de la media [20].

- **DBSCAN:** Es un algoritmo de agrupamiento basado en densidad que identifica grupos de puntos fuertemente conectados y clasifica como ruido aquellos que no alcanzan la densidad mínima requerida [21]. En este estudio se emplearon un radio de vecindad $eps = 5$ y un número mínimo de puntos $MinPts = 5$, parámetros ajustados de manera empírica con el fin de optimizar la separación entre regiones densas y áreas dispersas dentro del espacio de características analizado.

Se realizaron visualizaciones mediante boxplots estratificados por etiqueta ('A' y 'N') para identificar los outliers detectados por cada técnica, complementadas con gráficos de dispersión bivariados para evidenciar los outliers detectados por DBSCAN. El análisis se centró en los registros identificados como atípicos por al menos dos de las metodologías, dado que cada técnica presenta limitaciones: el Z-score puede subestimar valores extremos en distribuciones asimétricas, mientras que el criterio del IQR puede ser conservador, de modo que no todos los valores fuera del rango corresponden necesariamente a comportamientos fisiológicos anómalos.

C. Tratamiento e imputación de valores atípicos

Para el tratamiento de los valores atípicos, se consideraron aquellos datos que se encontraban fuera de los rangos fisiológicos esperados. Estos valores se reemplazaron por NaN y se realizó un análisis para identificar a qué épocas pertenecían, considerando la etiqueta correspondiente. Posteriormente, se aplicó un proceso de imputación utilizando diferentes técnicas: imputación por mediana e imputación aleatoria. Estas metodologías se implementaron de manera independiente para las etiquetas de apnea ('A') y normales ('N'), con el fin de preservar las características específicas de cada condición fisiológica.

D. Transformación de características y balanceo de clases

Se aplicaron la transformación de Yeo-Johnson y el logaritmo natural a las características extraídas, con el objetivo de estabilizar la varianza y aproximar las distribuciones a una forma normal, lo que facilitó el análisis estadístico posterior. La transformación de Yeo-Johnson permitió manejar tanto valores positivos como negativos [22], resultando especialmente útil para características derivadas de señales fisiológicas que podían tomar valores negativos o cercanos a cero.

Para corregir el desbalance entre las clases de salida, se implementó un balanceo de clases mediante submuestreo aleatorio (undersampling) de la clase

mayoritaria y sobre-muestreo sintético (SMOTE) de la clase minoritaria. Estas técnicas permitieron ajustar la proporción de épocas con y sin eventos de apnea, evitando que los análisis posteriores se vieran sesgados hacia la clase más frecuente.

E. Análisis de clúster

Para evaluar la capacidad de las variables seleccionadas de capturar patrones entre las épocas de apnea y normales, se aplicó K-Means, definiendo el número de clusters como $n = 2$.

El análisis se realizó considerando tres escenarios: el dataset original (sin balance de clases), el dataset con submuestreo aleatorio y el dataset con sobre-muestreo sintético (SMOTE), para observar cómo el balance de clases influye en la formación de clusters.

Asimismo, se evaluó la correspondencia entre las asignaciones de clúster generadas por K-Means y las etiquetas verdaderas del conjunto de datos. Para ello, se emplearon métricas de comparación estándar, incluyendo la precisión global, el F1-Score, el Adjusted Rand Index (ARI) y la Normalized Mutual Information (NMI), con el objetivo de cuantificar el grado de concordancia entre la agrupación no supervisada y las clases reales.

III. Resultados y análisis

Los resultados de este estudio se estructuran en cinco secciones principales. En primer lugar, se presenta el análisis exploratorio del conjunto de datos. A continuación, se describe la detección y evaluación de valores atípicos. Posteriormente, se detalla el tratamiento e imputación de dichos valores. En la cuarta sección, se expone la transformación de características junto con las estrategias de balanceo de clases. Finalmente, se presentan los resultados del análisis de clúster.

A. Análisis exploratorio del conjunto de datos

Para el análisis de las características, se excluyeron aquellas con valores de SpO_2 iguales a cero, resultando en 2,286 épocas sin eventos de apnea y 1,506 con eventos respiratorios. Las variables se analizaron mediante boxplots normalizados, divididos según la etiqueta de apnea y no apnea, generando gráficos para las características de ECG (Figura 1), SpO_2 (Figura 2) y flujo respiratorio (Figura 3).

En las características extraídas de la señal ECG mediante los picos R, la mediana y métricas de variabilidad, como la varianza de los intervalos RR y el RMSSD, presentaron valores bajos y no mostraron

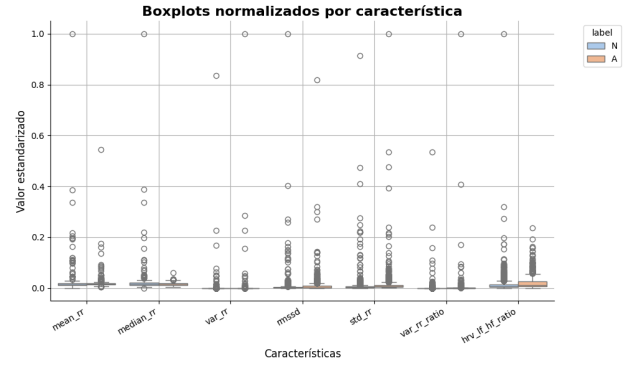


Figura 1: Boxplots normalizados de las características de ECG.

diferencias apreciables entre los grupos. Se observó además una presencia considerable de valores atípicos, lo que probablemente redujo la sensibilidad de la mediana para reflejar diferencias reales entre condiciones.

En las características de SpO_2 (Figura 2), se evidenciaron diferencias entre medianas. Para métricas como el valor mínimo y el promedio, la mediana fue menor en las épocas con apnea en comparación con aquellas sin apnea, reflejando la desaturación de oxígeno presente durante los eventos respiratorios. En contraste, las características que reflejaban variabilidad, como la desviación estándar, presentaron medianas mayores en el grupo de épocas con apnea, debido a los cambios de desaturación y recuperación, mientras que en las épocas sin eventos estos valores se mantuvieron relativamente constantes. Para la característica del valor máximo, se observó una mayor dispersión en las épocas con apnea, aunque las medianas fueron similares entre ambos grupos, indicando que ambos tipos de épocas alcanzaron valores máximos comparables.




Figura 2: Boxplots normalizados de las características de SpO_2 .

En la señal de flujo respiratorio (Figura 3), las medianas de las características evaluadas fueron mayores en el grupo con apnea. Este aumento se explicó porque, durante los eventos de apnea, el flujo permaneció la mayor parte del tiempo cercano a cero, generando una concentración de puntos positivos




Figura 3: Boxplots normalizados de las características de flujo respiratorio.

alrededor de ese nivel y desplazando las métricas de tendencia central hacia valores más altos. Por otro lado, las métricas asociadas a la variabilidad, como la desviación estándar y las componentes espectrales en los rangos de 0–0.1 Hz y 0.4–0.5 Hz, presentaron valores mayores en las épocas con apnea. Esto reflejó las fluctuaciones de flujo generadas por el cese y la posterior recuperación respiratoria, donde el esfuerzo inspiratorio compensatorio produjo oscilaciones más marcadas en la señal. En contraste, durante las épocas sin eventos respiratorios, el flujo se mantuvo más estable y dentro de un rango acotado (aproximadamente entre -0.6 y 0.6), reflejando un patrón respiratorio continuo.

Considerando el sesgo y la presencia de valores atípicos en las variables analizadas, se evaluó la correlación de Spearman (Figura 4).

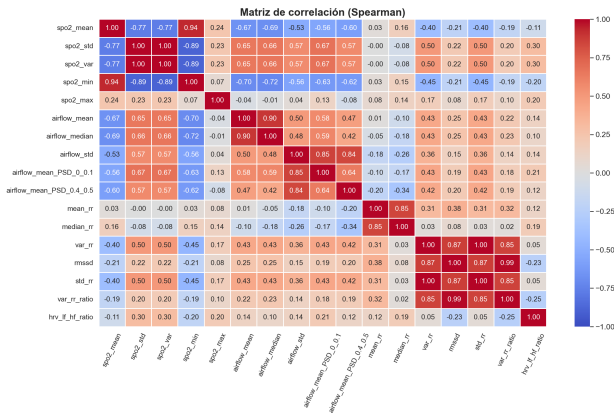


Figura 4: Boxplots normalizados de las características de flujo respiratorio.

En la correlación de Spearman se evidenciaron asociaciones monótonas elevadas. Se registraron correlaciones perfectas ($\rho = 1,0$) entre `spo2_std` y `spo2_var`, así como entre `var_rr` y `std_rr`, reflejando la estrecha relación estadística entre estas métricas, dado que ambas describen propiedades de dispersión derivadas de la misma señal. De manera consistente, la alta

correlación entre `rmssd` y `var_rr_ratio` ($\rho = 0,99$), junto con la observada entre `mean_rr` y `median_rr` ($\rho = 0,85$), evidenció la consistencia interna de las medidas de variabilidad cardíaca calculadas a partir de los intervalos RR.

Asimismo, las correlaciones positivas entre `airflow_std` y las componentes espectrales `airflow_mean_PSD_0.0.1` ($\rho = 0,85$) y `airflow_mean_PSD_0.4.0.5` ($\rho = 0,84$) indicaron que los incrementos en la variabilidad del flujo respiratorio se asociaron con mayores fluctuaciones energéticas en las bandas de baja y alta frecuencia. Finalmente, las correlaciones negativas entre `spo2_std`, `spo2_var` y `spo2_min` ($\rho = -0,89$) confirmaron que una mayor dispersión en la saturación de oxígeno coincidió con descensos más pronunciados en los valores mínimos de SpO_2 , reflejando los efectos característicos de las desaturaciones durante los eventos de apnea.

B. Detección y análisis de valores atípicos

Para el análisis de valores atípicos se implementaron diagramas de boxplot separados por etiquetas de apnea y normal, considerando las características de cada señal y tres técnicas de detección de outliers: IQR, Z-score y DBSCAN. En las características de la señal ECG se identificaron casos en los que los outliers presentaban valores fisiológicamente no plausibles, como se muestra en la Figura 5, correspondiente a la característica `median_rr`.




Figura 5: Detección de outliers por etiqueta en la característica `median_rr`. Los métodos empleados incluyen IQR, Z-score y DBSCAN.

En la métrica `median_rr` se identificaron valores atípicos compartidos entre métodos: 9 en épocas sin apnea y 9 en épocas con apnea. Algunos de estos outliers alcanzaron valores extremos mayores a 4 s, equivalentes a frecuencias cardíacas extremadamente bajas. Estos casos se asociaron principalmente a errores en la detección de picos R o artefactos transitorios de señal.

De manera similar, se evaluaron las características `RMSSD`, `Mean_RR` y el cociente `LF/HF` con el fin de identificar épocas con valores no plausibles.

Para la característica RMSSD, se consideró que en adultos sanos los valores típicos oscilaban aproximadamente entre 27 y 72 ms [23]. Valores sustancialmente superiores no reflejaron variabilidad fisiológica real y se atribuyeron a artefactos, latidos no corregidos o errores en la detección de picos R. Por esta razón, se estableció un criterio conservador en el cual cualquier época con RMSSD >0.2 s (200 ms) se clasificó como *incorrecta* y sus valores se reemplazaron por NaN, generando 680 épocas marcadas como NaN.

Los intervalos RR fisiológicos en adultos en reposo suelen encontrarse entre 0.6 y 1.2 s, correspondientes a frecuencias cardíacas de 50 a 100 lat/min [24]. Para permitir cierta variabilidad durante el sueño, se amplió el rango plausible a 0.3–3 s:

- RR <0.3 s implica frecuencias superiores a 200 lat/min, poco probables en individuos dormidos, generalmente asociados a errores de detección o artefactos.
- RR >3 s corresponde a frecuencias inferiores a 20 lat/min, no compatibles con registros fisiológicos normales durante el sueño.

En consecuencia, cualquier época en la que Median_RR o Mean_RR se encontrara fuera de este rango se clasificó como no fisiológica y se reemplazó por NaN, generando 4 épocas marcadas como NaN.

En cuanto al cociente LF/HF, que puede presentar alta variabilidad, valores extremadamente altos se debieron frecuentemente a artefactos, pérdida de señal o estimaciones espectrales inestables. Aunque un rango entre 0.5 y 2.0 se asocia típicamente con equilibrio autonómico [23], se adoptó un umbral conservador de LF/HF >10 para considerar las épocas como no válidas. Dichos valores se marcaron como NaN, generando 156 épocas clasificadas como NaN. El resumen de la cantidad de épocas asignadas como NaN se presenta en el Cuadro 1.

Cuadro 1: Resumen de épocas clasificadas como NaN según la característica y criterio de plausibilidad.

Característica	Criterio / Umbral	Épocas
RMSSD	>0.2 s	680
Median_RR	fuera 0.3–3 s	4
Mean_RR	fuera 0.3–3 s	4
LF/HF	>10	156

Para la señal de SpO₂, la característica spo2_min presentó la diferencia más marcada en valores atípicos no fisiológicos (Figura 6). Durante las épocas normales (N) se identificaron 16 valores atípicos compartidos por los tres métodos de detección, mientras que en las épocas con apnea (A) se registraron 29 valores con coincidencia entre métodos. Adicionalmente, en N se encontraron 6 valores de SpO₂ inferiores al 70 %, en contraste con 309 valores en A.




Figura 6: Detección de outliers por etiqueta en la característica *spo2_min*. Los métodos empleados incluyen IQR, Z-score y DBSCAN.

Dado que los dispositivos de oximetría son precisos principalmente en el rango 70–100 % [24], estos valores probablemente correspondieron a artefactos derivados de pérdida de señal o movimiento del sensor, fenómenos más frecuentes durante los episodios obstructivos. Por esta razón, se estableció como criterio que cualquier época en la que spo2_min presentara un valor ****inferior al 70 %**** se clasificaría como no confiable. En tales casos, tanto spo2_min como todas las características derivadas de la señal de SpO₂ en esa misma época se asignaron como NaN, resultando en un total de 315 épocas clasificadas como NaN.

Este enfoque permitió identificar y enmascarar valores fisiológicamente no plausibles en todas las características, asegurando que los análisis posteriores se basaran únicamente en datos confiables.

Por otro lado, las características extraídas de la señal de flujo, como se evidencia en la Figura 7 para la característica airflow_median, se encontraron dentro del rango fisiológico esperado, presentando valores plausibles.




Figura 7: Detección de outliers por etiqueta en la característica *airflow_median*. Los métodos empleados incluyen IQR, Z-score y DBSCAN.

Asimismo, al representar los datos mediante un diagrama de dispersión, se observó que la distribución formaba nubes densas y continuas, sin regiones claramente separadas de alta o baja densidad (Figura 8). Bajo los parámetros seleccionados para DBSCAN (ϵ y min_samples = 5), el algoritmo no identificó ningún punto como outlier. Esto indica que, con este

nivel de sensibilidad, no existían observaciones suficientemente alejadas o aisladas como para ser consideradas valores atípicos. Por tanto, los valores de esta característica se conservaron para análisis posteriores.

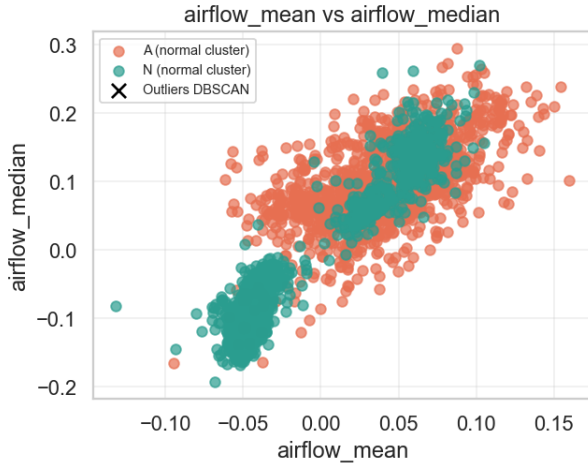


Figura 8: Diagrama de dispersión de la característica *airflow_mean* vs *airflow_median* por etiqueta. Se observan nubes densas y continuas de datos, sin puntos aislados identificados como outliers por DBSCAN (ϵ y $min_samples = 5$).

C. Tratamiento e imputación de valores atípicos

Los valores NaN se presentaron principalmente en las características derivadas de la señal ECG, concentrándose en las épocas clasificadas como apnea, donde más del 30 % de las observaciones de estas métricas se registraron como NaN. En contraste, durante las épocas normales (N), la proporción de valores faltantes se redujo aproximadamente al 13 %. Las variables asociadas a SpO₂ (*spo2_std*, *spo2_mean*, *spo2_max*, *spo2_min*, *spo2_var*) presentaron valores faltantes en 315 épocas, representando un 8.3 % del total de observaciones, concentrándose principalmente en épocas de apnea del sujeto 2.

Se consideraron dos métodos de imputación: la imputación por mediana por grupo y la imputación aleatoria por grupo. Esto permitió analizar cómo cada técnica modificaba la distribución y la variabilidad de las variables. La imputación se aplicó por grupos de épocas (apnea vs. normal), dado que se identificaron diferencias entre ambas condiciones. Este enfoque garantizó que los valores imputados no distorsionaran la comparación entre grupos ni alteraran la interpretación de las diferencias fisiológicas. Dado que únicamente las características derivadas de las señales de SpO₂ y ECG presentaron valores nulos, estas fueron las variables consideradas en el análisis.

En la técnica de imputación por mediana, se evidenció un cambio en la distribución de los datos, especialmente durante las épocas de apnea, donde se concentraba la mayoría de los valores NaN. En todas las características analizadas se observó un pico pronunciado en la distribución, acompañado de una reducción del rango intercuartílico en los diagramas de boxplot. Esto indica que la imputación tendió a concentrar los valores alrededor de la mediana, reduciendo la variabilidad natural de la señal. Este comportamiento se aprecia, por ejemplo, en la característica *rmssd* de la señal ECG (Figura 9).

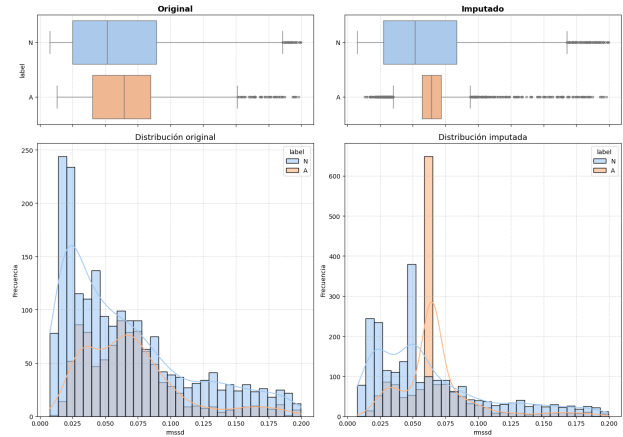


Figura 9: Distribución de la característica *rmssd* de la señal ECG por etiqueta (apnea vs. normal) tras la imputación por mediana.

En la imputación aleatoria por grupo en las características derivadas de ECG y SpO₂, la distribución de los datos se mantuvo muy similar a la original. Esto indica que este método preservó la variabilidad fisiológica de cada época sin introducir concentraciones artificiales de valores. Tal efecto se evidenció en la característica *rmssd* de la señal ECG, como se observa en la Figura 10.

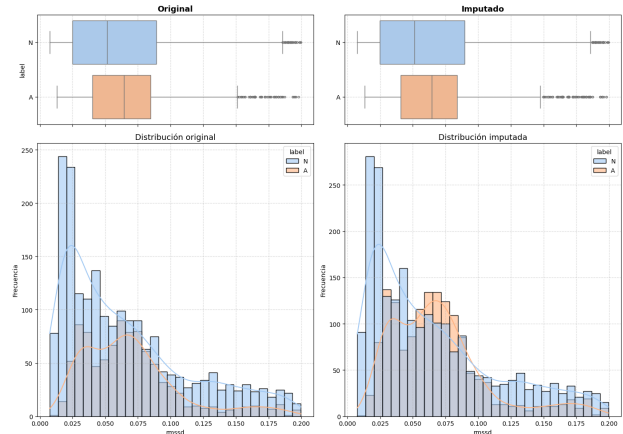


Figura 10: Distribución de la característica *rmssd* de la señal ECG por etiqueta (apnea vs. normal) tras la imputación aleatoria por grupo.

Teniendo en cuenta las características transformadas mediante la imputación aleatoria, se realizó la normalización por grupo para evidenciar diferencias entre las etiquetas. Las distribuciones normalizadas se presentan para la señal ECG (Figura 11) y la señal SpO₂ (Figura 12).




Figura 11: Distribución normalizada de las características derivadas de la señal ECG por etiqueta (apnea vs. normal).




Figura 12: Distribución normalizada de las características derivadas de la señal SpO₂ por etiqueta (apnea vs. normal).

Después de la depuración de los valores considerados fuera de rango, se observó un patrón diferenciado entre las épocas clasificadas como apnea (A) y normales (N) en las métricas derivadas de la señal ECG.

Las variables Mean_RR, Median_RR y Var_RR_Ratio mostraron medianas ligeramente más altas durante las épocas de apnea, con un rango intercuartílico relativamente estrecho. Esto sugiere que, en promedio, los intervalos RR y su variabilidad relativa fueron mayores durante los eventos de apnea, pero con menor dispersión entre épocas.

En contraste, Var_RR, RMSSD, Std_RR y HRV_LF/HF_Ratio presentaron medianas mayores durante las épocas de apnea, acompañadas de un rango intercuartílico más amplio, lo que reflejó una mayor heterogeneidad en la respuesta autonómica. Destaca RMSSD, que mostró el rango intercuartílico más amplio en las épocas normales, indicando que la variabilidad de la frecuencia cardíaca se mantuvo

significativa incluso fuera de los eventos de apnea. En el caso de HRV_LF/HF_Ratio, el aumento de la mediana durante las épocas de apnea evidenció un predominio simpático moderado, probablemente inducido por la hipoxemia intermitente y los despertares repetidos, lo que provocó una retirada vagal y un aumento relativo de la actividad simpática, tal como se ha reportado en pacientes con apnea moderada [25].

Este comportamiento difirió de las características de la señal ECG mostradas en la Figura 1, donde no se observaron diferencias apreciables entre etiquetas. Tras la depuración de los valores atípicos, como se muestra en la Figura 11, se evidenció el patrón fisiológico, previamente enmascarado por los outliers.

En las métricas derivadas de la señal de saturación de oxígeno, durante las épocas de apnea se observó un descenso en la mediana de SpO_{2_min} y SpO_{2_mean}, reflejando la desaturación característica de estos eventos. SpO_{2_var} y SpO_{2_std} presentaron valores mayores durante las épocas de apnea, evidenciando una mayor variabilidad de la saturación asociada a las fluctuaciones de oxigenación.

En SpO_{2_max} se observó un ligero incremento de la mediana, sugiriendo que la saturación máxima se mantuvo relativamente estable entre épocas de apnea y normales, posiblemente debido a la recuperación parcial de oxigenación tras cada episodio. Asimismo, las épocas de apnea presentaron un rango intercuartílico más amplio, indicando mayor dispersión de los valores de saturación, coherente con la heterogeneidad en duración e intensidad de los eventos apnéicos.

D. Transformación de características y balanceo de clases

Se aplicaron dos tipos de transformaciones a las variables: logarítmica natural y Yeo-Johnson. Como se observa en la Figura 13, la transformación de Yeo-Johnson corrigió de manera significativa la asimetría en variables clave. Por ejemplo, en var_rr el sesgo original era 1.93; la transformación logarítmica lo redujo levemente a 1.87, mientras que Yeo-Johnson lo disminuyó notablemente a 0.32.

La transformación mediante Yeo-Johnson generó distribuciones más uniformes, redujo la influencia de valores atípicos y amplió el rango intercuartílico, mejorando la comparabilidad entre grupos. Esto permitió diferenciar con mayor claridad las distribuciones de épocas de apnea y normales. Estas variables fueron utilizadas posteriormente en el análisis de clúster.

Debido al desbalance en los datos originales (apnea: 1,587; normal: 3,898), se aplicó una técnica de submuestreo (*undersampling*) aleatoria, obteniéndose

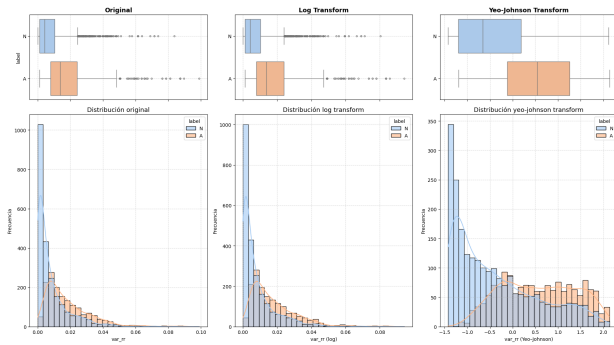


Figura 13: Distribución de la característica *var_rr* por etiqueta (apnea vs. normal) tras aplicar las transformaciones logarítmica natural y Yeo-Johnson.

un conjunto equilibrado de 3,174 épocas, con 1,587 de apnea y 1,587 normales. Asimismo, se implementó la técnica *SMOTE*, generando un total de 4,622 épocas, distribuidas equitativamente entre apnea (2,311) y normales (2,311).

E. Análisis de clúster

Se realizó un análisis de clúster considerando el desbalance de los datos originales. Los resultados obtenidos fueron los siguientes:

■ Datos originales:

- Accuracy: 0.9336
- F1-Score: 0.9236
- ARI (Adjusted Rand Index): 0.7518
- NMI (Normalized Mutual Information): 0.6809

Reporte detallado por clase:

- Normal (N): precisión 0.99, recall 0.90, F1-Score 0.94
- Apnea (A): precisión 0.87, recall 0.99, F1-Score 0.92

■ Con submuestreo aleatorio (*undersampling*):

- Accuracy: 0.9389
- F1-Score: 0.9416
- ARI: 0.7704
- NMI: 0.6956

Reporte detallado por clase:

- Normal (N): precisión 0.98, recall 0.89, F1-Score 0.94
- Apnea (A): precisión 0.90, recall 0.99, F1-Score 0.94

■ Con *SMOTE*:

- Accuracy: 0.9455
- F1-Score: 0.9477
- ARI: 0.7938
- NMI: 0.7192

Reporte detallado por clase:

- Normal (N): precisión 0.99, recall 0.90, F1-Score 0.94
- Apnea (A): precisión 0.91, recall 0.99, F1-Score 0.95

Estos resultados indican que el análisis de clúster mostró un desempeño global alto incluso con los datos originales, con métricas de precisión y recall superiores al 90 % para la mayoría de las clases. La aplicación de técnicas de balanceo de clases, como *undersampling* y *SMOTE*, permitió mejorar ligeramente la consistencia en la clasificación y equilibrar las métricas entre las épocas normales y de apnea. En particular, *SMOTE* proporcionó la mayor uniformidad en los resultados, evidenciando que la generación de observaciones sintéticas contribuyó a mitigar parcialmente el desbalance original entre las clases.

IV. Conclusiones

En este estudio se desarrolló un análisis integral de señales fisiológicas —ECG, SpO₂ y flujo respiratorio— con el fin de caracterizar alteraciones asociadas a los eventos de apnea del sueño. Las métricas temporales y frecuenciales extraídas evidenciaron diferencias consistentes entre épocas con y sin apnea, especialmente en la desaturación transitoria de oxígeno y en los cambios en la variabilidad respiratoria y cardíaca durante eventos obstructivos.

La detección de valores atípicos mediante IQR, Z-score y DBSCAN permitió identificar registros no fisiológicos asociados principalmente a fallas en la detección de picos R, artefactos y pérdidas de señal. Su depuración resultó fundamental para garantizar la integridad del análisis posterior. Tras este proceso, se observó que la mayor proporción de datos faltantes se concentró en las características derivadas de ECG, particularmente durante la apnea, mientras que SpO₂ y flujo respiratorio mostraron menor afectación.

La imputación aleatoria por clase se consolidó como la estrategia más adecuada para preservar la variabilidad fisiológica original, superando alternativas más restrictivas como la imputación por mediana. De igual forma, la aplicación de la transformación Yeo-Johnson permitió corregir la asimetría y el sesgo presentes en varias variables, mejorando su distribución y facilitando la diferenciación entre épocas normales y de apnea. Asimismo, el análisis de clúster, complementado con técnicas de balanceo como *SMOTE*, reveló agrupamientos coherentes con los patrones fisiológicos característicos de ambas condiciones.

En conjunto, los resultados obtenidos demuestran la utilidad de las características extraídas y de las metodologías aplicadas para describir y distinguir

los mecanismos respiratorios, cardiovasculares y de oxigenación involucrados en la apnea del sueño. Además, este trabajo establece un marco metodológico que puede servir como base para el desarrollo de algoritmos de detección y predicción orientados a la anticipación temprana de eventos respiratorios.

Aunque los hallazgos son consistentes, el estudio presenta limitaciones relacionadas con el tamaño y la diversidad del conjunto de datos, lo que podría restringir la generalización de los resultados y deberá abordarse en investigaciones futuras.

Referencias

- [1] Nicola Canessa et al. "Obstructive sleep apnea: brain structural changes and neurocognitive function before and after treatment". eng. En: *American Journal of Respiratory and Critical Care Medicine* 183.10 (mayo de 2011), págs. 1419-1426. ISSN: 1535-4970. DOI: 10.1164/rccm.201005-06930C.
- [2] Debora Valecchi et al. "Prognostic Significance of Obstructive Sleep Apnea in a Population of Subjects with Interstitial Lung Diseases". En: *Pulmonary Therapy* 9.2 (feb. de 2023), págs. 223-236. ISSN: 2364-1754. DOI: 10.1007/s41030-023-00215-1. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10203065/> (visitado 03-06-2025).
- [3] Santiago Bottia, Hannia Barrios-Bermúdez y Diego Rosselli. "Prevalencia de apnea de sueño en Colombia: un análisis de las bases de datos del Ministerio de Salud". es. En: *Iatreia* 37.1 (2024). Number: 1. ISSN: 2011-7965. DOI: 10.17533/udea.iatreia.222. URL: <https://revistas.udea.edu.co/index.php/iatreia/article/view/351336> (visitado 07-09-2024).
- [4] Salim Surani y Pahnwat Taweeseedt. "Obstructive Sleep Apnea: New Perspective". En: *Medicina* 59.1 (dic. de 2022), pág. 75. ISSN: 1010-660X. DOI: 10.3390/medicina59010075. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9862185/> (visitado 07-09-2024).
- [5] Mohammed Alzoubaidi y Babak Mokhlesi. "Obstructive sleep apnea during REM sleep: Clinical relevance and therapeutic implications". En: *Current opinion in pulmonary medicine* 22.6 (nov. de 2016), págs. 545-554. ISSN: 1070-5287. DOI: 10.1097/MCP.0000000000000319. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5084837/> (visitado 31-05-2025).
- [6] Filip Franciszek Karuga et al. "REM-OSA as a Tool to Understand Both the Architecture of Sleep and Pathogenesis of Sleep Apnea—Literature Review". en. En: *Journal of Clinical Medicine* 12.18 (ene. de 2023). Number: 18 Publisher: Multidisciplinary Digital Publishing Institute, pág. 5907. ISSN: 2077-0383. DOI: 10.3390/jcm12185907. URL: <https://www.mdpi.com/2077-0383/12/18/5907> (visitado 31-05-2025).
- [7] Narat Srivali et al. "The use of continuous positive airway pressure in COPD-OSA overlap syndrome: A systematic review". En: *Sleep Medicine* 108 (ago. de 2023), págs. 55-60. ISSN: 1389-9457. DOI: 10.1016/j.sleep.2023.05.025. URL: <https://www.sciencedirect.com/science/article/pii/S1389945723001946> (visitado 20-07-2025).
- [8] Min Qiao et al. "Long term adherence to continuous positive Airway pressure in mild obstructive sleep apnea". En: *BMC Pulmonary Medicine* 23 (sep. de 2023), pág. 320. ISSN: 1471-2466. DOI: 10.1186/s12890-023-02612-3. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10472589/> (visitado 20-07-2025).
- [9] Katrien Hertegonne y Fré Bauters. "The value of auto-adjustable CPAP devices in pressure titration and treatment of patients with obstructive sleep apnea syndrome". eng. En: *Sleep Medicine Reviews* 14.2 (abr. de 2010), págs. 115-119. ISSN: 1532-2955. DOI: 10.1016/j.smr.2009.07.001.
- [10] Karin Gardner Johnson y Douglas Clark Johnson. "Treatment of sleep-disordered breathing with positive airway pressure devices: technology update". eng. En: *Medical Devices (Auckland, N.Z.)* 8 (2015), págs. 425-437. ISSN: 1179-1470. DOI: 10.2147/MDER.S70062.
- [11] Praveen Kumar Tyagi y Dheeraj Agrawal. "Automatic detection of sleep apnea from a single-lead ECG signal based on spiking neural network model". En: *Computers in Biology and Medicine* 179 (sep. de 2024), pág. 108877. ISSN: 0010-4825. DOI: 10.1016/j.combiomed.2024.108877. URL: <https://www.sciencedirect.com/science/article/pii/S0010482524009624> (visitado 11-12-2024).
- [12] Mikiyas Petros Ayalew, Hundessa Daba Nemomssa y Gizeaddis Lamesgin Simegn. "Sleep apnea syndrome detection and classification of severity level from ECG and SpO2 signals". en. En: *Health Technology* 5.0 (nov. de 2021). Number: 0 Publisher: AME Publishing Company. ISSN: 2616-2717. DOI: 10.21037/ht-21-18. URL:

- <https://ht.amegroups.org/article/view/7077> (visitado 19-10-2024).
- [13] Thomas Penzel et al. *Apnea-ECG Database*. 2000. DOI: 10.13026/C23W2R. URL: <https://physionet.org/content/apnea-ecg/> (visitado 01-06-2025).
- [14] Sofía Martín-González et al. "Combining Heart Rate Variability and Oximetry to Improve Apneic Event Screening in Non-Desaturating Patients". En: *Sensors (Basel, Switzerland)* 23.9 (abr. de 2023), pág. 4267. ISSN: 1424-8220. DOI: 10.3390/s23094267. URL: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10181515/> (visitado 08-06-2025).
- [15] Xilin Li, Sai Ling y Steven Su. "A Hybrid Feature Selection and Extraction Methods for Sleep Apnea Detection Using Bio-Signals". En: *Sensors* 20 (ago. de 2020), pág. 4323. DOI: 10.3390/s20154323.
- [16] Tao Wang, Changhua Lu y Guohao Shen. "Detection of Sleep Apnea from Single-Lead ECG Signal Using a Time Window Artificial Neural Network". En: *BioMed Research International* 2019 (dic. de 2019), pág. 9768072. ISSN: 2314-6133. DOI: 10.1155/2019/9768072. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC6948296/> (visitado 05-10-2025).
- [17] Mikiyas Petros Ayalew, Hundessa Daba Nemomssa y Gizeaddis Lamesgin Simegn. "Sleep apnea syndrome detection and classification of severity level from ECG and SpO2 signals". en. En: *Health Technology* 5.0 (nov. de 2021). ISSN: 2616-2717. DOI: 10.21037/ht-21-18. URL: <https://ht.amegroups.org/article/view/7077/pdf> (visitado 05-10-2025).
- [18] Xilin Li, Sai Ling y Steven Su. "A Hybrid Feature Selection and Extraction Methods for Sleep Apnea Detection Using Bio-Signals". En: *Sensors* 20 (ago. de 2020), pág. 4323. DOI: 10.3390/s20154323.
- [19] *Interquartile Range to Detect Outliers in Data*. en-US. Section: Python Programs. URL: <https://www.geeksforgeeks.org/machine-learning/interquartile-range-to-detect-outliers-in-data/>.
- [20] *Z score for Outlier Detection - Python*. en-US. Section: Machine Learning. URL: <https://www.geeksforgeeks.org/machine-learning/z-score-for-outlier-detection-python/>.
- [21] *DBSCAN Clustering in ML - Density based clustering - GeeksforGeeks*. URL: <https://www.geeksforgeeks.org/machine-learning/dbscan-clustering-in-ml-density-based-clustering/>.
- [22] *Yeo-Johnson Transform*. en-US. Section: Machine Learning. URL: <https://www.geeksforgeeks.org/machine-learning/yeo-johnson-transform/> (visitado 25-11-2025).
- [23] *HRV Metrics Explained: SDNN vs RMSSD for Health Apps*. en. URL: <https://www.spikeapi.com/blog/understanding-hrv-metrics-a-deep-dive-into-sdnn-and-rmssd> (visitado 17-11-2025).
- [24] "Normal Electrocardiography (ECG) Intervals: Normal Electrocardiography Intervals". En: (oct. de 2024). Publication: Medscape - eMedicine. URL: <https://emedicine.medscape.com/article/2172196-overview?form=fpf> (visitado 17-11-2025).
- [25] Lorne J Gula et al. "Heart Rate Variability in Obstructive Sleep Apnea: A Prospective Study and Frequency Domain Analysis". En: *Annals of Noninvasive Electrocardiology : The Official Journal of the International Society for Holter and Noninvasive Electrocardiology, Inc* 8.2 (abr. de 2003), págs. 144-149. ISSN: 1082-720X. DOI: 10.1046/j.1542-474X.2003.08209.x. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC6932147/> (visitado 19-11-2025).